

# MAT02035 - Modelos para dados correlacionados

Revisão de vetores, matrizes, valores esperados e variâncias

Rodrigo Citton P. dos Reis  
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL  
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA  
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2022

# Vetores e matrizes

# Introdução

- ▶ Vetores e matrizes nos permitem realizar operações matemáticas comuns (por exemplo, adição, subtração e multiplicação) em uma **coleção de números**.
  - ▶ Eles também facilitam a descrição de métodos estatísticos para dados multivariados.
  - ▶ Aproveitaremos esta aula para introduzirmos algumas funções do R para vetores e matrizes.
- ▶ Nossa principal motivação para usá-los é a maneira concisa e compacta com as quais técnicas estatísticas para **análise de dados longitudinais** podem ser apresentadas quando expressas em termos de **vetores** e **matrizes**.

## Definições e conceitos básicos

- ▶ Uma **matriz** é um arranjo retangular de elementos ordenados por linhas e colunas.

$$A = \begin{pmatrix} 2 & 7 & 11 & 5 \\ 4 & 9 & 3 & 1 \\ 13 & 8 & 2 & 6 \end{pmatrix}.$$

- ▶  $A$  é uma matriz com três linhas e quatro colunas.

## Definições e conceitos básicos

- ▶ O **elemento** ou **entrada** na  $i$ -ésima linha e  $j$ -ésima coluna da matriz é referido como  $(i, j)$ -ésimo elemento da matriz.
- ▶ Se denotarmos  $a_{ij}$  como o elemento da  $i$ -ésima linha e  $j$ -ésima coluna da matriz  $A$ , então

$$\begin{array}{llll} a_{11} = 2, & a_{12} = 7, & a_{13} = 11, & a_{14} = 5; \\ a_{21} = 4, & a_{22} = 9, & a_{23} = 3, & a_{24} = 1; \\ a_{31} = 13, & a_{32} = 8, & a_{33} = 2, & a_{34} = 6. \end{array}$$

# Definições e conceitos básicos

- ▶ A **dimensão** de uma matriz é o número de linhas e colunas na matriz.
- ▶ Por convenção, o número de linhas é apresentado primeiro, e depois o número de colunas.
  - ▶ A matriz  $A$  é uma matriz  $3 \times 4$  ("3 por 4").

## Definições e conceitos básicos

- ▶ Um **vetor** é um caso especial de matriz, contendo ou uma única linha ou uma única coluna.

$$V = \begin{pmatrix} 2 \\ 4 \\ 9 \\ 7 \\ 3 \end{pmatrix}.$$

- ▶  $V$  é um vetor (coluna)  $5 \times 1$ .
- ▶ A dimensão de um vetor é o seu **comprimento** (o número de elementos).
- ▶ Por fim, um **escalar** é um único elemento (um vetor com um elemento ou uma matriz  $1 \times 1$ ).

# Escalares, vetores e matrizes no R

## Um escalar

- ▶ Basta criar um novo objeto com um único valor.

```
b <- 5
```

```
b
```

```
## [1] 5
```



# Escalares, vetores e matrizes no R

## Um vetor

- ▶ A forma mais simples de se criar um vetor no R é utilizando a função `c()` (concatenar).

`c(a, b, c, ...)`

`a, b, c, ...`

Um ou mais objetos a serem combinados em um vetor.

# Escalares, vetores e matrizes no R

## Um vetor

```
V <- c(2, 4, 9, 7, 3)
```

```
V
```

```
## [1] 2 4 9 7 3
```

```
length(V)
```

```
## [1] 5
```

# Escalares, vetores e matrizes no R

## Uma matriz

- ▶ Podemos pensar em uma matriz como uma combinação de  $p$  vetores, em que cada vetor tenha comprimento igual a  $n$ .
- ▶ Por serem uma combinação de vetores, cada função terá um ou mais vetores como inputs e retornará uma matriz.

Função	Descrição
<code>cbind()</code>	Combina vetores em <i>colunas</i> em uma matriz/dataframe.
<code>rbind()</code>	Combina vetores em <i>linhas</i> em uma matriz/dataframe.
<code>matrix()</code>	Cria uma matriz com o número desejado de linhas e colunas a partir de um único vetor.

# Escalares, vetores e matrizes no R

## Uma matriz

```
A <- matrix(data = c(2, 7, 11, 5,  
                     4, 9, 3, 1,  
                     13, 8, 2, 6),  
            nrow = 3, byrow = TRUE)
```

A

```
##      [,1] [,2] [,3] [,4]  
## [1,]    2    7   11    5  
## [2,]    4    9    3    1  
## [3,]   13    8    2    6
```

```
dim(A)
```

```
## [1] 3 4
```

## Vetor resposta e matriz de covariáveis

- ▶ Exemplos de vetores e matrizes que desempenham papéis-chave na análise de dados longitudinais são o **vetor resposta**,  $Y$ , e a **matriz de covariáveis**,  $X$ .

**Table 1:** Dados de um indivíduo participante do estudo do Chumbo.

Chumbo no sangue	Grupo de tratamento	Semana
30.8	0	0
26.9	0	1
25.8	0	4
23.8	0	6

## Vetor resposta e matriz de covariáveis

- $Y$  denota o vetor de medidas repetidas da variável resposta, então

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ Y_4 \end{pmatrix} = \begin{pmatrix} 30.8 \\ 26.9 \\ 25.8 \\ 23.8 \end{pmatrix}.$$

## Vetor resposta e matriz de covariáveis

- $X$  denota a matriz de covariáveis associadas ao vetor de medidas repetidas

$$X = \begin{pmatrix} X_{11} & X_{12} & X_{13} \\ X_{21} & X_{22} & X_{23} \\ X_{31} & X_{32} & X_{33} \\ X_{41} & X_{42} & X_{43} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 4 \\ 1 & 0 & 6 \end{pmatrix}.$$

# Matriz transposta

- ▶ A **transposta** é a função que troca as linhas e as colunas de uma matrix.
  - ▶ A primeira linha se torna a primeira coluna, a segunda linha se torna a segunda coluna, e assim por diante.
- ▶ Iremos denotar a transposta de uma matriz  $A$  por  $A'$  (“ $A$  linha”).
  - ▶ Alguns livros denotam a transposta de  $A$  por  $A^T$ .



## Matriz transposta

- Considere novamente a matriz  $3 \times 4$   $A$

$$A = \begin{pmatrix} 2 & 7 & 11 & 5 \\ 4 & 9 & 3 & 1 \\ 13 & 8 & 2 & 6 \end{pmatrix}.$$

- A matriz transposta de  $A$  é

$$A' = \begin{pmatrix} 2 & 4 & 13 \\ 7 & 9 & 8 \\ 11 & 3 & 2 \\ 5 & 1 & 6 \end{pmatrix}.$$

que é uma matriz  $4 \times 3$ .

# Matriz transposta

- Como um vetor é uma matriz com uma única linha ou única coluna, se

$$V = \begin{pmatrix} 2 \\ 4 \\ 9 \\ 7 \\ 3 \end{pmatrix}, \quad \text{então} \quad V' = (2 \ 4 \ 9 \ 7 \ 3).$$

## Matriz transposta no R

```
A
```

```
##           [,1] [,2] [,3] [,4]
## [1,]         2   7  11   5
## [2,]         4   9   3   1
## [3,]        13   8   2   6
```

```
t(A)
```

```
##           [,1] [,2] [,3]
## [1,]         2   4  13
## [2,]         7   9   8
## [3,]        11   3   2
## [4,]         5   1   6
```

## Matrizes quadradas e simétricas

- ▶ Uma matriz é dita **quadrada** se esta tem o mesmo número de linhas e colunas.
- ▶ Uma matriz quadrada é **simétrica** se esta é igual à sua matriz transposta.

$$S = \begin{pmatrix} 2 & 3 & 7 & 11 \\ 3 & 9 & 1 & 2 \\ 7 & 1 & 5 & 8 \\ 11 & 2 & 8 & 4 \end{pmatrix}.$$

- ▶  $S$  é uma matriz simétrica, pois a é igual à sua matriz transposta

$$S' = \begin{pmatrix} 2 & 3 & 7 & 11 \\ 3 & 9 & 1 & 2 \\ 7 & 1 & 5 & 8 \\ 11 & 2 & 8 & 4 \end{pmatrix}.$$

## Matrizes quadradas e simétricas

```
S <- matrix(data = c(2, 3, 7, 11,  
                    3, 9, 1, 2,  
                    7, 1, 5, 8,  
                    11, 2, 8, 4),  
            nrow = 4, ncol = 4,  
            byrow = TRUE)  
all.equal(S, t(S))
```

```
## [1] TRUE
```

## Matrizes quadradas e simétricas

- ▶ Exemplos de matrizes simétricas que desempenham papel importante na análise de dados longitudinais são as matrizes de **covariância** e **correlação** para as correspondentes medidas repetidas nos mesmos indivíduos.
- ▶ Por fim, uma matriz **diagonal** é um caso especial de uma matriz quadrada simétrica que tem entradas não nulas (diferentes de zero) somente para as posições da **diagonal principal**.
  - ▶ Os elementos da diagonal principal são aqueles na mesma linha e coluna ( $a_{ii}$ ), da parte superior esquerda para a parte inferior direita da matriz.

$$D = \begin{pmatrix} 2 & 0 & 0 & 0 \\ 0 & 9 & 0 & 0 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 4 \end{pmatrix}.$$

## Matrizes quadradas e simétricas

- ▶ A matriz diagonal contendo apenas 1s na diagonal principal é conhecida como a matriz **identidade** e é denotada por  $I$  ou  $I_n$ , em que  $n$  denota a dimensão da matriz identidade.

$$I_4 = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}.$$

## Matrizes quadradas e simétricas

```
# cria matriz diagonal  
I <- diag(x = rep(1, 4))  
I
```

```
##      [,1] [,2] [,3] [,4]  
## [1,]    1    0    0    0  
## [2,]    0    1    0    0  
## [3,]    0    0    1    0  
## [4,]    0    0    0    1
```

```
# retorna os elementos da diagonal principal da matriz  
diag(x = S)
```

```
## [1] 2 9 5 4
```



# Operações aritméticas

- ▶ A adição e subtração de matrizes são definidas apenas para matrizes com a mesma dimensão.
  - ▶ Matrizes devem ter o mesmo número de linhas e colunas.
- ▶ A soma de duas matrizes é obtida por adicionar os seus elementos correspondentes.

# Operações aritméticas

## Soma

$$\begin{pmatrix} 2 & 7 & 11 \\ 4 & 9 & 3 \\ 13 & 8 & 2 \end{pmatrix} + \begin{pmatrix} 3 & 2 & 14 \\ 7 & 8 & 4 \\ 6 & 5 & 9 \end{pmatrix} = \begin{pmatrix} 2+3 & 7+2 & 11+14 \\ 4+7 & 9+8 & 3+4 \\ 13+6 & 8+5 & 2+9 \end{pmatrix}$$
$$= \begin{pmatrix} 5 & 9 & 25 \\ 11 & 17 & 7 \\ 19 & 13 & 11 \end{pmatrix}.$$

# Operações aritméticas

## Subtração

$$\begin{pmatrix} 2 & 7 & 11 \\ 4 & 9 & 3 \\ 13 & 8 & 2 \end{pmatrix} - \begin{pmatrix} 3 & 2 & 14 \\ 7 & 8 & 4 \\ 6 & 5 & 9 \end{pmatrix} = \begin{pmatrix} 2-3 & 7-2 & 11-14 \\ 4-7 & 9-8 & 3-4 \\ 13-6 & 8-5 & 2-9 \end{pmatrix} \\ = \begin{pmatrix} -1 & 5 & -3 \\ -3 & 1 & -1 \\ 7 & 3 & -7 \end{pmatrix}.$$

## Operações aritméticas

```
G <- matrix(data = c(2, 7, 11, 4, 9, 3, 13, 8, 2),  
            nrow = 3, byrow = TRUE)  
J <- matrix(data = c(3, 2, 14, 7, 8, 4, 6, 5, 9),  
            nrow = 3, byrow = TRUE)  
  
G + J
```

```
##      [,1] [,2] [,3]  
## [1,]    5    9   25  
## [2,]   11   17    7  
## [3,]   19   13   11
```

```
G - J
```

```
##      [,1] [,2] [,3]  
## [1,]   -1    5  -3  
## [2,]   -3    1  -1  
## [3,]    7    3  -7
```

## Multiplicação de matriz por um escalar

- A multiplicação de uma matriz por um escalar é formada pela multiplicação de cada elemento da matriz pelo escalar

$$A = \begin{pmatrix} 2 & 7 & 11 & 5 \\ 4 & 9 & 3 & 1 \\ 13 & 8 & 2 & 6 \end{pmatrix}, \quad \text{então} \quad 2A = \begin{pmatrix} 4 & 14 & 22 & 10 \\ 8 & 18 & 6 & 2 \\ 26 & 16 & 4 & 12 \end{pmatrix}.$$

## Multiplicação de matriz por um escalar

```
2 * A
```

```
##      [,1] [,2] [,3] [,4]  
## [1,]    4   14  22   10  
## [2,]    8   18   6    2  
## [3,]   26   16   4   12
```

## Multiplicação de matrizes

A multiplicação de duas matrizes  $A$  e  $B$ , denotada por  $AB$ , é definida somente se o número de colunas de  $A$  é igual ao número de linhas de  $B$ .

- ▶ Se  $A$  é uma matriz  $p \times q$  e  $B$  é uma matriz  $q \times r$ , então o produto das duas matrizes  $AB$  é uma matriz  $p \times r$ .

Seja  $C$  o produto de  $A$  e  $B$ ,

$$C = AB,$$

o  $(i, j)$ -ésimo elemento de  $C$  é a soma dos produtos dos correspondentes na  $i$ -ésima linha de  $A$  e  $j$ -ésima coluna de  $B$ .

- ▶ Por exemplo,

$$c_{ij} = \sum_{k=1}^q a_{ik} b_{kj} = a_{i1} b_{1j} + a_{i2} b_{2j} + \dots + a_{iq} b_{qj}, i = 1, \dots, p, j = 1, \dots, r.$$

# Multiplicação de matrizes

## Exemplo

$$A = \begin{pmatrix} 2 & 7 & 11 \\ 4 & 9 & 3 \\ 13 & 8 & 2 \end{pmatrix} \quad \text{e} \quad B = \begin{pmatrix} 1 & 2 \\ 3 & 1 \\ 2 & 4 \end{pmatrix}$$

$$\begin{aligned} AB &= \begin{pmatrix} (2 \times 1) + (7 \times 3) + (11 \times 2) & (2 \times 2) + (7 \times 1) + (11 \times 4) \\ (4 \times 1) + (9 \times 3) + (3 \times 2) & (4 \times 2) + (9 \times 1) + (3 \times 4) \\ (13 \times 1) + (8 \times 3) + (2 \times 2) & (13 \times 2) + (8 \times 1) + (2 \times 4) \end{pmatrix} \\ &= \begin{pmatrix} 45 & 55 \\ 37 & 29 \\ 41 & 42 \end{pmatrix} \end{aligned}$$

- Note que a ordem da multiplicação é muito importante. Se  $A$  e  $B$  são matrizes quadradas de mesma dimensão, então, em geral,  $AB$  não é igual a  $BA$ .



## Multiplicação de matrizes

```
A <- matrix(data = c(2, 7, 11, 4, 9, 3, 13, 8, 2),  
            nrow = 3, byrow = TRUE)  
B <- matrix(data = c(1, 2, 3, 1, 2, 4),  
            nrow = 3, byrow = TRUE)  
A %*% B
```

```
##      [,1] [,2]  
## [1,]  45  55  
## [2,]  37  29  
## [3,]  41  42
```

# Multiplicação de matrizes

```
G %*% J
```

```
##           [,1] [,2] [,3]  
## [1,]    121  115  155  
## [2,]     93   95  119  
## [3,]    107  100  232
```

```
J %*% G
```

```
##           [,1] [,2] [,3]  
## [1,]    196  151   67  
## [2,]     98  153  109  
## [3,]    149  159   99
```

# Multiplicação de matrizes

```
# CUIDADO!
```

```
G * J
```

```
##      [,1] [,2] [,3]  
## [1,]    6   14  154  
## [2,]   28   72   12  
## [3,]   78   40   18
```

# Multiplicação de matrizes

- ▶ A multiplicação de um vetor por uma matriz é uma operação particularmente importante que desempenha um papel chave na análise longitudinal.
- ▶ Seja  $B$  um vetor  $p \times 1$  e  $X$  uma matriz  $n \times p$ .

Então, o produto

$$C = XB,$$

é um vetor  $n \times 1$  com

$$c_i = \sum_{k=1}^p x_{ik} b_k, i = 1, \dots, n.$$

## Multiplicação de matrizes

- Retornando ao exemplo do **chumbo no sangue**: seja  $Y$  o vetor de medidas repetidas da variável resposta, e  $X$  uma matriz de covariáveis associadas a  $Y$ ,

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ Y_4 \end{pmatrix} \quad \text{e} \quad X = \begin{pmatrix} X_{11} & X_{12} & X_{13} \\ X_{21} & X_{22} & X_{23} \\ X_{31} & X_{32} & X_{33} \\ X_{41} & X_{42} & X_{43} \end{pmatrix}.$$

## Multiplicação de matrizes

- Um modelo de regressão linear para a média de cada resposta pode ser expresso na notação de vetor e matriz como

$$E(Y) = X\beta,$$

em que  $E(Y)$  denota o valor esperado de  $Y$  e  $\beta$  é um vetor  $3 \times 1$  de coeficientes de regressão,

$$\beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix}.$$

# Multiplicação de matrizes

Especificamente, o produto

$$E(Y) = X\beta,$$

é um vetor  $4 \times 1$

$$\begin{pmatrix} E(Y_1) \\ E(Y_2) \\ E(Y_3) \\ E(Y_4) \end{pmatrix} = \begin{pmatrix} X_{11} & X_{12} & X_{13} \\ X_{21} & X_{22} & X_{23} \\ X_{31} & X_{32} & X_{33} \\ X_{41} & X_{42} & X_{43} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} \beta_1 X_{11} + \beta_2 X_{12} + \beta_3 X_{13} \\ \beta_1 X_{21} + \beta_2 X_{22} + \beta_3 X_{23} \\ \beta_1 X_{31} + \beta_2 X_{32} + \beta_3 X_{33} \\ \beta_1 X_{41} + \beta_2 X_{42} + \beta_3 X_{43} \end{pmatrix}.$$

# Matriz inversa

A **inversa** de uma matriz quadrada  $A$ , denotada por  $A^{-1}$ , é definida como uma matriz quadrada cujo os elementos são tais que

$$AA^{-1} = A^{-1}A = I,$$

em que  $I$  é a matriz identidade.

- **Observação:** a inversa de uma matriz nem sempre existe. A inversa de uma matriz somente existe se a matriz é **não-singular**.



# Matriz inversa

- ▶ Por fim, o **determinante** de uma matriz quadrada é um escalar denotado por  $|A|$ .
  - ▶ Para uma matriz  $2 \times 2$   $A$ , o determinante é

$$|A| = a_{11}a_{22} - a_{12}a_{21}.$$

- ▶ Uma propriedade interessante do determinante é que ele fornece um teste da existência da matriz inversa.
  - ▶ Se  $|A| \neq 0$ , então a inversa de  $A$  existe; se  $|A| = 0$ , então a matriz é dita ser **singular** e a inversa de  $A$  não existe.
- ▶ O determinante também tem um papel importante na definição da **distribuição normal multivariada** (determinante da matriz de covariância).

## Matriz inversa

```
# determinante de G
```

```
det(G)
```

```
## [1] -730
```

```
# G é singular?
```

```
det(G) != 0
```

```
## [1] TRUE
```

```
# inversa de G
```

```
solve(G)
```

```
##           [,1]      [,2]      [,3]
```

```
## [1,]  0.008219178 -0.1013699  0.10684932
```

```
## [2,] -0.042465753  0.1904110 -0.05205479
```

```
## [3,]  0.116438356 -0.1027397  0.01369863
```

## Propriedades de valores esperados e variâncias

# Introdução

Seja  $Y$  uma variável aleatória que assume valores de acordo com uma função densidade se  $Y$  é contínua ou uma função massa de probabilidade se  $Y$  é discreta.

- ▶ O **valor esperado** (esperança, ou média) de  $Y$  é denotado por

$$\mu = E(Y) = \int y dF_Y(y).$$

- ▶ A **variância** de  $Y$ , denotada por  $\sigma^2 = \text{Var}(Y)$ , é uma medida de variabilidade em torno da média de  $Y$ , e definida por

$$\sigma^2 = \text{Var}(Y) = E\{Y - E(Y)\}^2.$$

# Introdução

- ▶ O **desvio padrão** de  $Y$  é uma medida de variabilidade expressa na unidade (de medida) original de  $Y$ , e definido como  $\sigma = \sqrt{\text{Var}(Y)}$ .
- ▶ Por fim, a covariância entre duas variáveis aleatórias,  $X$  e  $Y$ , é definida como

$$\text{Cov}(X, Y) = E[\{X - E(X)\}\{Y - E(Y)\}].$$

- ▶ A covariância é uma medida de **dependência linear** entre  $X$  e  $Y$ .
  - ▶ Se  $X$  e  $Y$  são **independentes**, então  $\text{Cov}(X, Y) = 0$ .
- ▶ Note que a covariância de uma variável com ela mesma é a variância,  $\text{Cov}(Y, Y) = \text{Var}(Y)$ .

## Propriedades de valores esperados e variâncias

Sejam  $X$  e  $Y$  duas variáveis aleatórias (possivelmente dependentes) e  $a$  e  $b$  duas constantes. O valor esperado tem as seguintes propriedades:

1.  $E(a) = a$
  2.  $E(bX) = bE(X)$
  3.  $E(a + bX) = a + bE(X)$
  4.  $E(aX + bY) = aE(X) + bE(Y)$
  5.  $E(XY) \neq E(X)E(Y)$  (a menos que  $X$  e  $Y$  sejam **independentes**)
- Se  $g(\cdot)$  é função linear, então  $E[g(Y)] = g(E[Y])$ .

# Propriedades de valores esperados e variâncias

A variância tem as seguintes propriedades:

1.  $\text{Var}(a) = 0$
2.  $\text{Var}(bY) = b^2 \text{Var}(Y)$
3.  $\text{Var}(a + bY) = b^2 \text{Var}(Y)$
4.  $\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$
5.  $\text{Var}(aX - bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) - 2ab \text{Cov}(X, Y)$

# Propriedades de valores esperados e variâncias

Em particular, se  $X$  e  $Y$  são **dependentes**, então

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y),$$

e

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y).$$



## Propriedades de valores esperados e variâncias

- Por fim, notamos que o valor esperado e a variância podem ser aplicados para um vetor aleatório. Seja  $Y$  um vetor resposta  $n \times 1$  (portanto, um vetor coluna; medidas repetidas em  $n$  ocasiões distintas),

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}.$$

## Propriedades de valores esperados e variâncias

Então,

$$E(Y) = \begin{pmatrix} E(Y_1) \\ E(Y_2) \\ \vdots \\ E(Y_n) \end{pmatrix},$$

e

$$\text{Cov}(Y) = \begin{pmatrix} \text{Var}(Y_1) & \text{Cov}(Y_1, Y_2) & \dots & \text{Cov}(Y_1, Y_n) \\ \text{Cov}(Y_2, Y_1) & \text{Var}(Y_2) & \dots & \text{Cov}(Y_2, Y_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(Y_n, Y_1) & \text{Cov}(Y_n, Y_2) & \dots & \text{Var}(Y_n) \end{pmatrix}.$$

# Avisos

- ▶ **Para casa:**
  - ▶ Demonstre as propriedades de valores esperados e variâncias listadas nos slides 46 e 47.
  - ▶ Ler o Capítulo 1 do livro “**Applied Longitudinal Analysis**”. Caso já tenha lido o Cap. 1, leia o Capítulo 2.
- ▶ **Próxima aula:** Dados longitudinais: conceitos básicos.

## Bons estudos!

$$\begin{bmatrix} M & A & \dots & T \\ \vdots & \vdots & \ddots & \vdots \\ R & I & \dots & X \end{bmatrix}$$