

# MAT02035 - Modelos para dados correlacionados

## Modelando a estrutura de covariância

Rodrigo Citton P. dos Reis  
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL  
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA  
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2023

# Introdução

# Introdução

- ▶ Uma vez que uma das características definidoras dos **dados longitudinais** é que eles **são correlacionados**, devemos considerar abordagens para **modelar** apropriadamente a **covariância** ou dependência do tempo entre as medidas repetidas obtidas nos mesmos indivíduos.
- ▶ Quando um modelo apropriado para a covariância é adotado, erros padrão corretos são obtidos e inferências válidas sobre os parâmetros de regressão podem ser feitas.
- ▶ Levar em consideração a covariância entre medidas repetidas geralmente aumenta a eficiência ou a precisão com a qual os parâmetros de regressão podem ser estimados; ou seja, a correlação positiva entre as medidas repetidas reduz a variabilidade da estimativa de mudança ao longo do tempo dentro dos indivíduos.

# Introdução

- ▶ Além disso, quando há dados ausentes, a modelagem correta da covariância é frequentemente um requisito para obter estimativas válidas dos parâmetros de regressão.
- ▶ Em geral, a falha em levar em consideração a covariância entre as medidas repetidas resultará em estimativas incorretas da variabilidade da amostragem e pode levar a inferências científicas enganosas.

# Introdução

- ▶ Os dados longitudinais apresentam **dois aspectos** dos dados que **requerem modelagem**: a **resposta média** ao longo do tempo e a **covariância**.
- ▶ Embora esses dois aspectos dos dados possam ser modelados separadamente, eles estão **inter-relacionados**.
- ▶ As escolhas de modelos para resposta média e covariância são **interdependentes**.
- ▶ Um modelo para a covariância deve ser escolhido com base em algum modelo assumido para a resposta média.
- ▶ A covariância entre qualquer par de resíduos, digamos  $[Y_{ij} - \mu_{ij}(\beta)]$  e  $[Y_{ik} - \mu_{ik}(\beta)]$ , depende do modelo para a média condicional.

# Introdução

- ▶ Um modelo para a covariância deve ser escolhido com base em algum modelo para a resposta média; este representa uma tentativa de levar em consideração a covariância entre os resíduos que resultam de um modelo específico para a média.
- ▶ Uma escolha diferente de modelo para a média ou, além disso, qualquer especificação incorreta do modelo para a média, pode potencialmente resultar em uma escolha diferente de modelo para a covariância.
- ▶ Como resultado dessa interdependência entre os modelos de média e covariância, precisaremos desenvolver uma estratégia geral de modelagem que leve essa interdependência em consideração.

# Introdução

Três abordagens gerais podem ser distinguidas:

- (1) padrão de covariância "não estruturado" ou arbitrário ;
- (2) modelos de padrão de covariância ;
- (3) estrutura de covariância de efeitos aleatórios .

## Covariância não estruturada



# Covariância não estruturada

- ▶ **Apropriada** quando o **delineamento** é **balanceado** e o **número de ocasiões** de medições é relativamente **pequeno**.
- ▶ Nenhuma estrutura explícita é assumida além da **homogeneidade de covariância entre diferentes indivíduos**,  $\text{Cov}(Y_i) = \Sigma_i = \Sigma$ .
- ▶ **Principal vantagem**: nenhuma suposição sobre os padrões de variância e covariâncias.

# Covariância não estruturada

- ▶ Com  $n$  ocasiões de medição, a matriz de covariância “não estruturada” possui  $n \times (n + 1)/2$  parâmetros:
  - ▶ as  $n$  variâncias ( $\sigma_j^2 = \text{Var}[Y_{ij}]$ ) e as  $n \times (n - 1)/2$  covariâncias ( $\sigma_{jk} = \text{Cov}[Y_{ij}, Y_{ik}]$ ) duas-a-duas,

$$\text{Cov}(Y_i) = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1n} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \cdots & \sigma_n^2 \end{pmatrix}.$$

# Covariância não estruturada

## Potenciais desvantagens:

- ▶ O número de parâmetros de covariância cresce rapidamente com o número de ocasiões de medição:
  - ▶  $n = 3$ , o número de parâmetros de covariância é 6;
  - ▶  $n = 5$ , o número de parâmetros de covariância é 15;
  - ▶  $n = 10$ , o número de parâmetros de covariância é 55.
- ▶ Quando o número de parâmetros de covariância é grande, em relação ao tamanho da amostra, é provável que a estimativa seja muito instável.
- ▶ O uso de uma covariância não estruturada é atraente apenas quando  $N$  é grande em relação a  $n \times (n + 1)/2$ .
- ▶ A covariância não estruturada é problemática quando há medições irregulares no tempo.

## Modelos de padrão de covariância

# Modelos de padrão de covariância

- ▶ Ao tentar impor alguma estrutura à covariância, um **equilíbrio** sutil precisa ser alcançado.
  - ▶ Com **pouca estrutura**, pode haver **muitos parâmetros** a serem estimados com quantidade limitada de dados.
  - ▶ Com **muita estrutura**, risco potencial de **erros de especificação do modelo** e inferências enganosas a respeito de  $\beta$ .
- ▶ Este é o clássico **tradeoff** entre **viés** e **variância**.
- ▶ Os modelos de padrão de covariância têm como base **modelos de correlação serial** originalmente desenvolvidos para dados de **séries temporais**.
  - ▶ A seguir, veremos alguns destes modelos.

## Relação entre a covariância e a correlação

- Lembre que  $\rho_{jk} = \text{Corr}(Y_{ij}, Y_{ik})$  pode ser expresso como

$$\begin{aligned}\rho_{jk} &= \frac{\text{Cov}(Y_{ij}, Y_{ik})}{\sqrt{\text{Var}(Y_{ij})}\sqrt{\text{Var}(Y_{ik})}} \\ &= \frac{\sigma_{jk}}{\sigma_j \sigma_k} \\ \Rightarrow \sigma_{jk} &= \rho_{jk} \sigma_j \sigma_k.\end{aligned}$$

- Se assumirmos que  $\text{Var}(Y_{i1}) = \text{Var}(Y_{i2}) = \dots \text{Var}(Y_{in}) = \sigma^2$ , então  $\sigma_j = \sigma_k$  e  $\sigma_j \sigma_k = \sigma^2$ , e assim  $\sigma_{jk} = \rho_{jk} \sigma^2$ .
  - Ou seja, modelos de padrão de covariância podem ser obtidos a partir da especificação de um padrão da estrutura de correlação.

## Simetria composta

- ▶ Este padrão assume que a **variância é constante** entre as ocasiões, digamos  $\sigma^2$ , e  $\text{Corr}(Y_{ij}, Y_{ik}) = \rho$  para todo  $j$  e  $k$ .

$$\text{Cov}(Y_i) = \sigma^2 \begin{pmatrix} 1 & \rho & \rho & \cdots & \rho \\ \rho & 1 & \rho & \cdots & \rho \\ \rho & \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \rho & \cdots & 1 \end{pmatrix}.$$

- ▶ **Vantagem:** (parcimônia) possui apenas dois parâmetros, independentemente do número de ocasiões de medição.
- ▶ **Desvantagem:** Faz fortes suposições sobre variância e correlação que geralmente não são válidas com dados longitudinais.

# Toeplitz

- Assume que a variância é constante entre as ocasiões, digamos  $\sigma^2$ , e  $\text{Corr}(Y_{ij}, Y_{i,j+k}) = \rho_k$  para todo  $j$  e  $k$ .

$$\text{Cov}(Y_i) = \sigma^2 \begin{pmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{n-1} \\ \rho_1 & 1 & \rho_1 & \cdots & \rho_{n-2} \\ \rho_2 & \rho_1 & 1 & \cdots & \rho_{n-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho_{n-1} & \rho_{n-2} & \rho_{n-3} & \cdots & 1 \end{pmatrix}.$$

- Assume que a correlação entre as respostas em ocasiões adjacentes de medição é constante,  $\rho_1$ .



# Toeplitz

- ▶ Toeplitz é apropriado apenas quando as medições são feitas em intervalos de tempo iguais (ou aproximadamente iguais).
- ▶ A covariância Toeplitz possui  $n$  parâmetros ( $1$  parâmetro de variância e  $n - 1$  parâmetros de correlação).
- ▶ Um caso especial da covariância Toeplitz é a covariância **autorregressiva** (de primeira ordem).

# Autoregressiva

- Assume que a variância é constante entre as ocasiões, digamos  $\sigma^2$ , e  $\text{Corr}(Y_{ij}, Y_{i,j+k}) = \rho^k$  para todo  $j$  e  $k$ , e  $\rho \geq 0$ .

$$\text{Cov}(Y_i) = \sigma^2 \begin{pmatrix} 1 & \rho & \rho^2 & \dots & \rho^{n-1} \\ \rho & 1 & \rho & \dots & \rho^{n-2} \\ \rho^2 & \rho & 1 & \dots & \rho^{n-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho^{n-1} & \rho^{n-2} & \rho^{n-3} & \dots & 1 \end{pmatrix}.$$

- Parcimônia:** apenas 2 parâmetros, independentemente do número de ocasiões de medição.
- Somente apropriado quando as medições são feitas em intervalos de tempo iguais (ou aproximadamente iguais).

## Autoregressiva

- ▶ Simetria composta, Toeplitz e covariância autorregressiva assumem que as variâncias são constantes ao longo do tempo.
- ▶ Essa suposição pode ser relaxada considerando-se versões desses modelos com variâncias heterogêneas,  $\text{Var}(Y_{ij}) = \sigma_j^2$ .
- ▶ Um padrão heterogêneo de covariância autorregressiva:

$$\text{Cov}(Y_i) = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 & \rho^2\sigma_1\sigma_3 & \cdots & \rho^{n-1}\sigma_1\sigma_n \\ \rho\sigma_1\sigma_2 & \sigma_2^2 & \rho\sigma_2\sigma_3 & \cdots & \rho^{n-2}\sigma_2\sigma_n \\ \rho^2\sigma_1\sigma_3 & \rho\sigma_2\sigma_3 & \sigma_3^2 & \cdots & \rho^{n-3}\sigma_3\sigma_n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho^{n-1}\sigma_1\sigma_n & \rho^{n-2}\sigma_2\sigma_n & \rho^{n-3}\sigma_3\sigma_n & \cdots & \sigma_n^2 \end{pmatrix}.$$

e possui  $n + 1$  parâmetros ( $n$  parâmetros de variância e 1 parâmetro de correlação).

## Banded (em faixas)

- ▶ Assume que a correlação é zero além de algum intervalo especificado.
- ▶ Por exemplo, um padrão de covariância em faixas com tamanho de banda 3 pressupõe que  $\text{Corr}(Y_{ij}, Y_{i,j+k}) = 0$  para  $k \geq 3$ .
- ▶ É possível aplicar um padrão em faixas a qualquer um dos modelos de padrão de covariância considerados até o momento.

## Banded (em faixas)

- Um padrão de covariância de Toeplitz em faixas com um tamanho de banda 2 é dado por,

$$\text{Cov}(Y_i) = \sigma^2 \begin{pmatrix} 1 & \rho_1 & 0 & \cdots & 0 \\ \rho_1 & 1 & \rho_1 & \cdots & 0 \\ 0 & \rho_1 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix}.$$

em que  $\rho_2 = \rho_3 = \dots = \rho_{n-1} = 0$ .

- A estrutura banded faz suposições muito fortes sobre a rapidez com que a correlação cai para zero com o aumento da separação entre as ocasiões de medição.

# Exponencial

- ▶ Quando as ocasiões de medição não são igualmente espaçadas ao longo do tempo, o modelo autorregressivo pode ser generalizado da seguinte maneira.
- ▶ Denote os tempos de observação para o  $i$ -ésimo indivíduo por  $\{t_{i1}, \dots, t_{in}\}$  e assuma que a variância é constante em todas as ocasiões de medição, digamos  $\sigma^2$ , e

$$\text{Corr}(Y_{ij}, Y_{ik}) = \rho^{|t_{ij} - t_{ik}|}, \text{ para } \rho \geq 0.$$

- ▶ A correlação entre qualquer par de medidas repetidas diminui exponencialmente com as separações de tempo entre elas.

# Exponencial

- ▶ Este padrão é referido como **covariância “exponencial”** porque pode ser reexpressa como

$$\begin{aligned}\text{Cov}(Y_{ij}, Y_{ik}) &= \sigma^2 \rho^{|t_{ij} - t_{ik}|} \\ &= \sigma^2 \exp(-\theta |t_{ij} - t_{ik}|),\end{aligned}$$

em que  $\theta = -\log(\rho)$  ou  $\rho = \exp(-\theta)$  para  $\theta \geq 0$ .

- ▶ O modelo de covariância exponencial é invariante sob transformação linear da escala de tempo.
  - ▶ Se substituirmos  $t_{ij}$  por  $(a + bt_{ij})$  (por exemplo, se substituirmos o tempo medido em “semanas” pelo tempo medido em “dias”), a mesma forma para a matriz de covariância se mantém.

## Escolha entre modelos de padrão de covariância

- ▶ A escolha de modelos para covariância e média são interdependentes.
- ▶ A escolha do modelo de covariância deve ser baseada em um modelo “**maximal**” para a média que minimiza qualquer possível erro de especificação.
- ▶ Com delineamentos balanceados e um número muito pequeno de covariáveis discretas, escolha o “modelo saturado” para a resposta média.
- ▶ **Relembrando:** o **modelo saturado** inclui os efeitos principais do tempo (considerado como um fator dentro de indivíduo) e todos os outros efeitos principais, além de suas interações duas-a-duas e de ordem superiores.



## Escolha entre modelos de padrão de covariância

- ▶ De forma mais geral, quando o modelo saturado não puder ser empregado, um modelo maximal deve ser especificado para a média da resposta.
  - ▶ O modelo maximal deve ser, em certo sentido, o modelo mais elaborado para a resposta média que consideraríamos do ponto de vista do indivíduo.
- ▶ Uma vez escolhido o modelo maximal, a variância e a covariância residual podem ser usadas para selecionar o modelo apropriado para covariância.

## Escolha entre modelos de padrão de covariância

- ▶ Dado um modelo maximal para a média, uma sequência de modelos de padrão de covariância pode ser ajustada aos dados disponíveis.
- ▶ **A escolha** entre os modelos pode ser feita **comparando as verossimilhanças maximizadas** para cada um dos modelos de padrão de covariância.
- ▶ Ou seja, quando qualquer par de modelos é encaixado, uma estatística de **teste de razão de verossimilhanças** pode ser construída para comparar os modelos “completo” e “reduzido”.

## Escolha entre modelos de padrão de covariância

- ▶ Lembre-se que dois modelos são encaixados quando o modelo “reduzido” é um caso especial do modelo “completo”.
- ▶ Por exemplo, o modelo de simetria composta é um caso especial do modelo Toeplitz, desde que  $\rho_1 = \rho_2 = \dots = \rho_{n-1}$ .
- ▶ A estatística do teste da razão de verossimilhanças é obtido tomando-se o dobro da diferença das respectivas **log-verossimilhanças REML maximizadas**,

$$G^2 = 2(\hat{\ell}_{comp} - \hat{\ell}_{red}),$$

e comparando a estatística com uma distribuição qui-quadrado com graus de liberdade igual à diferença entre o número de parâmetros de covariância nos modelos completo e reduzido.

# Escolha entre modelos de padrão de covariância

- ▶ Para comparar modelos não encaixados, uma abordagem alternativa é o **Critério de Informação de Akaike (Akaike Information Criterion - AIC)**.
- ▶ De acordo com o AIC, dado um conjunto de modelos concorrentes para a covariância, **deve-se selecionar o modelo que minimiza**

$$\begin{aligned}AIC &= -2(\log\text{-vero. maximizada}) + 2(\text{número de parâmetros}) \\ &= -2(\hat{\ell} - c),\end{aligned}$$

em que  $\hat{\ell}$  é a **log-verossimilhança REML maximizada** e  $c$  é o número de parâmetros de covariância.

## Exemplo

## Experimento de Terapia por Exercício

- ▶ Neste estudo, os indivíduos foram designados para um dos dois programas de levantamento de peso para aumentar a força muscular.
  - ▶ **Tratamento 1:** o número de repetições dos exercícios foi aumentado à medida que os indivíduos se tornaram mais fortes.
  - ▶ **Tratamento 2:** o número de repetições foi mantido constante, mas a quantidade de peso foi aumentada à medida que os indivíduos se tornaram mais fortes.
- ▶ As medidas de força corporal foram realizadas na linha de base e nos dias 2, 4, 6, 8, 10 e 12.
- ▶ Vamos nos concentrar apenas nas medidas de força obtidas na linha de base (ou no dia 0) e nos dias 4, 6, 8 e 12.

## Experimento de Terapia por Exercício

- ▶ Antes de considerar modelos para a covariância, é necessário escolher um modelo maximal para a resposta média.
- ▶ Neste exemplo (delineamento balanceado e apenas dois grupos de tratamento), optamos pelo modelo saturado como o modelo maximal para a média.
- ▶ Primeiramente, vamos considerar uma matriz de **covariância não estruturada**.

## Modelo maximal com cov. não estruturada

```
library(nlme)

# matriz de covariância não estruturada
mod1 <- gls(fc ~ trt*dia,
            na.action = na.omit,

            corr = corSymm(form = ~ tempo | id),
            weights = varIdent(form = ~ 1 | tempo),

            method = "REML",
            data = af.longo)
```



## Matriz de covariância não estruturada estimada

```
library(lavaSearch2)

knitr::kable(
  getVarCov2(mod1)$Omega,
  digits = 3)
```

1	2	3	4	5
9.668	10.175	8.974	9.812	9.407
10.175	12.550	11.091	12.580	11.928
8.974	11.091	10.642	11.686	11.101
9.812	12.580	11.686	13.991	13.121
9.407	11.928	11.101	13.121	13.945

## Matriz de covariância não estruturada estimada

- ▶ Observe que a variância parece ser maior no final do estudo, quando comparada à variância na linha de base.
- ▶ A correspondente matriz de correlação pode ser obtida com

```
mod1$modelStruct$corStruct
```

```
## Correlation structure of class corSymm representing  
## Correlation:  
##   1      2      3      4  
## 2 0.924  
## 3 0.885 0.960  
## 4 0.844 0.949 0.958  
## 5 0.810 0.902 0.911 0.939
```

- ▶ Note que as correlações diminuem à medida que a separação do tempo entre as medidas repetidas aumenta.

## Modelo maximal com cov. autoregressiva

- ▶ Apesar do aparente aumento da variância ao longo do tempo, consideramos um **modelo autorregressivo** para a covariância.
- ▶ Este modelo é muito parcimonioso, com apenas dois parâmetros, um descrevendo a variância,  $\sigma^2$ , o outro a correlação,  $\rho$ .

```
# library(nlme)

# matriz de covariância autorregressiva
mod2 <- gls(fc ~ trt*dia,
            na.action = na.omit,

            corr = corAR1(form = ~ tempo | id),

            method = "REML",
            data = af.longo)
```

## Modelo maximal com cov. autoregressiva

- ▶ Quando um modelo autorregressivo de primeira ordem é ajustado aos dados, ele resulta nas seguintes estimativas dos parâmetros de variância e correlação

```
summary(mod2)$sigma^2
```

```
## [1] 11.86727
```

```
coef(mod2$modelStruct$corStruct,  
      uncons = FALSE, allCoef = TRUE)
```

```
##      Phi1
```

```
## 0.9401763
```

## Modelo maximal com cov. autoregressiva

- ▶ As correlações pareadas estimadas resultantes entre as cinco medições repetidas são fornecidas por

```
getVarCov(mod2)/summary(mod2)$sigma^2
```

```
## Marginal variance covariance matrix
##      [,1]    [,2]    [,3]    [,4]    [,5]
## [1,] 1.00000 0.94018 0.88393 0.83105 0.78133
## [2,] 0.94018 1.00000 0.94018 0.88393 0.83105
## [3,] 0.88393 0.94018 1.00000 0.94018 0.88393
## [4,] 0.83105 0.88393 0.94018 1.00000 0.94018
## [5,] 0.78133 0.83105 0.88393 0.94018 1.00000
## Standard Deviations: 1 1 1 1 1
```

- ▶ O modelo autorregressivo foi ajustado principalmente para fins ilustrativos; o modelo não é muito apropriado para esses dados, pois eles estão espaçados de forma desigual ao longo do tempo (ou seja, há um intervalo de quatro dias entre as duas primeiras medidas repetidas e as duas últimas medidas repetidas, mas todas as outras medidas repetidas adjacentes foram feitas com dois dias de intervalo).

## Modelo maximal com cov. exponencial

- A fim de contabilizar o intervalo de tempo desigual, um modelo exponencial para a covariância foi considerado, em que

$$\text{Cov}(Y_{ij}, Y_{ik}) = \sigma^2 \rho^{|t_{ij} - t_{ik}|},$$

para  $t_{i1} = 0$ ,  $t_{i2} = 4$ ,  $t_{i3} = 6$ ,  $t_{i4} = 8$  e  $t_{i5} = 12$  para todos os indivíduos.

## Modelo maximal com cov. exponencial

```
af.longo$dia.num <- as.numeric(as.character(af.longo$dia))  
  
# library(nlme)  
  
# matriz de covariância exponencial  
mod3 <- gls(fc ~ trt*dia,  
            na.action = na.omit,  
  
            corr = corExp(form = ~ dia.num | id),  
  
            method = "REML",  
            data = af.longo)
```

## Modelo maximal com cov. exponencial

- ▶ A variância e as correlações pareadas estimadas resultantes entre as cinco medições repetidas são fornecidas por

```
summary(mod3)$sigma^2
```

```
## [1] 11.87491
```

```
getVarCov(mod3)/summary(mod3)$sigma^2
```

```
## Marginal variance covariance matrix
```

```
##           [,1]    [,2]    [,3]    [,4]    [,5]
```

```
## [1,] 1.00000 0.91694 0.87804 0.84079 0.77096
```

```
## [2,] 0.91694 1.00000 0.95757 0.91694 0.84079
```

```
## [3,] 0.87804 0.95757 1.00000 0.95757 0.87804
```

```
## [4,] 0.84079 0.91694 0.95757 1.00000 0.91694
```

```
## [5,] 0.77096 0.84079 0.87804 0.91694 1.00000
```

```
## Standard Deviations: 1 1 1 1 1
```



## Modelo maximal com cov. exponencial

- Note que os declínios nas correlações estimadas dos modelos autorregressivo e exponencial são muito rápidos quando comparados aos declínios correspondentes do modelo de covariância não estruturada.

## Comparando os modelos

- ▶ A seguir, consideramos a escolha entre esses modelos de padrão de covariância.
- ▶ A log-verossimilhança REML maximizada e o AIC para cada um dos modelos de padrão de covariância são exibidos a seguir

```
anova(mod1, mod2, mod3, test = FALSE)
```

##	Model	df	AIC	BIC	logLik
## mod1	1	25	647.3399	724.6837	-298.6699
## mod2	2	12	645.0718	682.1968	-310.5359
## mod3	3	12	642.5459	679.6709	-309.2729

## Comparando os modelos

- ▶ Observe que existe uma hierarquia entre os modelos.
  - ▶ Os modelos autorregressivo e exponencial são encaixados no modelo de covariância não estruturada.
- ▶ As comparações dos modelos autorregressivo e exponencial com o modelo de covariância não estruturada podem ser feitas usando **testes de razão de verossimilhança (REML)**.
- ▶ No entanto, os modelos autorregressivo e exponencial não são modelos encaixados; ainda, ambos os modelos têm o mesmo número de parâmetros.
  - ▶ Como resultado, qualquer comparação entre esses dois modelos pode ser feita diretamente em termos de suas log-verossimilhanças maximizadas, uma vez que qualquer penalidade extraída por critérios de informação será a mesma em ambos os casos.

# Comparando os modelos

- ▶ Com base no teste da razão de verossimilhanças, há evidências de que o modelo autorregressivo não fornece um ajuste adequado para a covariância, quando comparado à covariância não estruturada ( $p < 0.05$ ).

```
anova(mod1, mod2)
```

##	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
##	mod1	1 25	647.3399	724.6837	-298.6699			
##	mod2	2 12	645.0718	682.1968	-310.5359	1 vs 2	23.73189	0.0337

## Comparando os modelos

- ▶ Por outro lado, o teste da razão de verossimilhanças, comparando a covariância exponencial e não estruturada, resulta em

```
anova(mod1, mod3)
```

##	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
##	mod1	1 25	647.3399	724.6837	-298.6699			
##	mod3	2 12	642.5459	679.6709	-309.2729	1 vs 2	21.20597	0.069

- ▶ Assim, a covariância exponencial fornece um ajuste adequado aos dados ( $p > 0.05$ ).
- ▶ Além disso, em termos do AIC, o modelo exponencial minimiza esse critério.

# Pontos fortes e fracos dos modelos de covariância

## Pontos fortes e fracos dos modelos de covariância

- ▶ Os modelos de padrão de covariância tentam caracterizar a covariância com um número relativamente pequeno de parâmetros.
- ▶ No entanto, muitos modelos (por exemplo, autorregressivo, Toeplitz e em faixas) são apropriados apenas quando medições repetidas são obtidas em intervalos iguais e não podem lidar com medições irregulares no tempo.
- ▶ Embora exista uma grande variedade de modelos para correlações, a escolha de modelos para variâncias é limitada.
- ▶ Eles não são adequados para modelar dados de delineamentos longitudinais inerentemente desbalanceados.

# Exercícios



# Exercícios

- ▶ Resolva os exercícios do Capítulo 7 do livro “**Applied Longitudinal Analysis**” (páginas 186 e 187).
  - ▶ O arquivo de dados (`dental.dta`) está no Moodle.

## Avisos

# Avisos

- ▶ **Próxima aula:** Modelos lineares de efeitos mistos.
- ▶ **Para casa:** ler o Capítulo 7 do livro “**Applied Longitudinal Analysis**”.
  - ▶ Caso ainda não tenha lido, leia também os Caps. 1, 2, 3, 4, 5 e 6.

## Bons estudos!

